

UNIVERSIDAD DEL VALLE DE GUATEMALA

Data Science



Proyecto 1. Obtención y Limpieza de datos

Erick Guerra - 23208
Fabian Morales - 23267
Olivier Viau - 23544

GUATEMALA, 20 de julio del 2026

Libro de Códigos

Establecimientos educativos de Guatemala, niveles Básico y Diversificado

Fuente: Portal BUSCAESTABLECIMIENTO del Ministerio de Educación de Guatemala, http://www.mineduc.gob.gt/BUSCAESTABLECIMIENTO_GE/

Fecha de extracción: 16 de julio de 2026

Versión del conjunto limpio: 1.0

Registros: 27,413

Variables: 20

El conjunto de datos crudo tenía 19 variables. Se eliminaron DEPARTAMENTO_CONSULTADO y NIVEL_CONSULTADO por ser redundantes con DEPARTAMENTO y NIVEL, y se agregaron tres variables derivadas durante la limpieza: TELEFONO_PRINCIPAL, TELEFONO_LISTA y MUNICIPIO_ES_ZONA_CAPITALINA. Esto deja el conjunto final en 20 variables.

CODIGO

Descripción: Identificador único del establecimiento educativo.

Tipo de dato: Texto

Dominio permitido: Cadena con el patrón ##-##-#####-##

Tratamiento aplicado: Se le quitaron espacios al inicio y al final. Se validó contra el patrón y el cien por ciento de los registros lo cumple. Se mantiene como texto para no perder los ceros a la izquierda.

DISTRITO

Descripción: Código del distrito educativo al que pertenece el establecimiento.

Tipo de dato: Texto

Dominio permitido: Existen dos formatos válidos reales según su longitud

Tratamiento aplicado: Se le quitaron espacios y se colapsaron espacios múltiples. Los valores faltantes se dejaron como valor nulo, sin inventar el código completo.

DEPARTAMENTO

Descripción: Departamento donde se ubica el establecimiento, según lo reporta la fuente.

Tipo de dato: Categórica

Dominio permitido: 23 valores, correspondientes a los 22 departamentos de Guatemala más Ciudad Capital como entrada separada, tal como lo reporta la fuente original

Tratamiento aplicado: Se normalizó a mayúsculas y se quitaron espacios. No se fusionó Ciudad Capital con Guatemala porque así viene estructurado en la fuente oficial.

MUNICIPIO

Descripción: Municipio donde se ubica el establecimiento.

Tipo de dato: Texto

Dominio permitido: Nombres de municipio, salvo en Ciudad Capital donde el valor es una zona, por ejemplo ZONA 2

Tratamiento aplicado: Se normalizó a mayúsculas y se quitaron espacios. Cuando el departamento es Ciudad Capital, el valor original de la fuente es una zona en lugar de un municipio, ya que administrativamente la capital es un solo municipio. Este valor no se modificó, y se documentó con la variable derivada MUNICIPIO_ES_ZONA_CAPITALINA.

ESTABLECIMIENTO

Descripción: Nombre del establecimiento educativo.

Tipo de dato: Texto

Dominio permitido: Libre

Tratamiento aplicado: Se quitaron espacios y se colapsaron espacios múltiples. Se corrigieron casos puntuales de puntuación mal usada, como guiones bajos en lugar de paréntesis. No se tocó la ortografía ni las tildes de nombres propios. Se buscaron duplicados parciales agrupando por municipio y comparando similitud de nombre y dirección con la librería RapidFuzz, sin eliminar ningún registro de forma automática.

DIRECCION

Descripción: Dirección física del establecimiento.

Tipo de dato: Texto

Dominio permitido: Libre

Tratamiento aplicado: Valores como guion, punto o SIN DATO se convirtieron a valor nulo. Se quitaron espacios y se homologó a mayúsculas.

TELEFONO

Descripción: Teléfono o teléfonos de contacto reportados, tal como vienen de la fuente, sin modificar.

Tipo de dato: Texto

Dominio permitido: Libre

Tratamiento aplicado: No se modificó. A partir de esta columna se generaron TELEFONO_PRINCIPAL y TELEFONO_LISTA.

SUPERVISOR

Descripción: Nombre del supervisor educativo a cargo.

Tipo de dato: Texto

Dominio permitido: Libre

Tratamiento aplicado: Se quitaron espacios y se colapsaron espacios múltiples. Se unificaron variantes del mismo nombre que solo se diferenciaban por el uso de tildes, dejando la forma más frecuente.

DIRECTOR

Descripción: Nombre del director del establecimiento.

Tipo de dato: Texto

Dominio permitido: Libre

Tratamiento aplicado: Valores como guion, punto o SIN DATO se convirtieron a valor nulo. Se quitaron espacios y se unificaron variantes por tildes de la misma forma que en SUPERVISOR. Es la variable con más valores faltantes del conjunto, alrededor del diecinueve por ciento.

NIVEL

Descripción: Nivel escolar que ofrece el establecimiento.

Tipo de dato: Categórica

Dominio permitido: BASICO, DIVERSIFICADO

Tratamiento aplicado: Ya estaba limpio. Se normalizó a mayúsculas de forma preventiva.

SECTOR

Descripción: Sector administrativo del establecimiento.

Tipo de dato: Categórica

Dominio permitido: OFICIAL, PRIVADO, MUNICIPAL, COOPERATIVA

Tratamiento aplicado: Se quitaron espacios y se normalizó a mayúsculas.

AREA

Descripción: Área geográfica donde se ubica el establecimiento.

Tipo de dato: Categórica

Dominio permitido: URBANA, RURAL, SIN ESPECIFICAR

Tratamiento aplicado: Se quitaron espacios y se normalizó a mayúsculas. SIN ESPECIFICAR se revisó y se confirmó como una categoría real de la fuente, no un error.

STATUS

Descripción: Estado operativo del establecimiento.

Tipo de dato: Categórica

Dominio permitido: ABIERTA, CERRADA DEFINITIVAMENTE, CERRADA TEMPORALMENTE, TEMPORAL NOMBRAMIENTO, TEMPORAL TITULOS

Tratamiento aplicado: Se quitaron espacios y se normalizó a mayúsculas. Las categorías TEMPORAL NOMBRAMIENTO y TEMPORAL TITULOS se confirmaron como válidas.

MODALIDAD

Descripción: Modalidad lingüística de atención.

Tipo de dato: Categórica

Dominio permitido: MONOLINGUE, BILINGUE

Tratamiento aplicado: Se quitaron espacios y se normalizó a mayúsculas.

JORNADA

Descripción: Jornada de atención del establecimiento.

Tipo de dato: Categórica

Dominio permitido: MATUTINA, VESPERTINA, NOCTURNA, DOBLE, SIN JORNADA, INTERMEDIA

Tratamiento aplicado: Se quitaron espacios y se normalizó a mayúsculas. INTERMEDIA se confirmó como categoría real y se agregó al dominio esperado.

PLAN

Descripción: Plan o frecuencia de clases del establecimiento.

Tipo de dato: Categórica

Dominio permitido: DIARIO REGULAR, SABATINO, DOMINICAL, FIN DE SEMANA, A DISTANCIA, VIRTUAL A DISTANCIA, SEMIPRESENCIAL y sus variantes, MIXTO, INTERCALADO, IRREGULAR

Tratamiento aplicado: Se quitaron espacios y se normalizó a mayúsculas. Se confirmaron las trece categorías reales que reporta la fuente.

DEPARTAMENTAL

Descripción: Oficina departamental del Ministerio de Educación a cargo del establecimiento.

Tipo de dato: Categórica

Dominio permitido: Catálogo de oficinas departamentales, puede haber más de una por departamento

Tratamiento aplicado: Se quitaron espacios y se normalizó a mayúsculas.

TELEFONO_PRINCIPAL

Descripción: Un solo número de teléfono, el primero que se pudo extraer y validar de la columna TELEFONO.

Tipo de dato: Texto numérico

Dominio permitido: Números de seis a ocho dígitos, o valor nulo si no se pudo extraer ninguno

Tratamiento aplicado: Variable derivada. Se extrajo con una expresión regular sobre TELEFONO. Sirve para cuando solo se necesita un teléfono de contacto por registro.

TELEFONO_LISTA

Descripción: Todos los números de teléfono válidos encontrados en la columna TELEFONO, separados por punto y coma.

Tipo de dato: Texto

Dominio permitido: Uno o más números separados por punto y coma, o valor nulo

Tratamiento aplicado: Variable derivada, generada junto con TELEFONO_PRINCIPAL. Conserva todos los números reportados cuando el establecimiento tiene más de uno.

MUNICIPIO_ES_ZONA_CAPITALINA

Descripción: Indica si el valor de MUNICIPIO corresponde a una zona de Ciudad Capital en lugar de un municipio real.

Tipo de dato: Booleano

Dominio permitido: Verdadero o falso

Tratamiento aplicado: Variable derivada. Es verdadero únicamente para los registros donde el departamento es Ciudad Capital. Permite identificar esos casos sin tener que revisar manualmente el texto de MUNICIPIO.

Columnas eliminadas del conjunto original

DEPARTAMENTO_CONSULTADO y NIVEL_CONSULTADO se eliminaron por ser completamente redundantes con DEPARTAMENTO y NIVEL. Coincidían en el cien por ciento de los registros y eran metadatos internos del proceso de extracción.

Duplicados

No se encontraron duplicados exactos en el conjunto de datos. Para duplicados parciales se usó la librería RapidFuzz, agrupando los registros por municipio y comparando similitud de nombre de establecimiento y dirección. Ningún registro se eliminó de forma automática, cada caso quedó documentado para revisión manual.

Archivos del proyecto

mineduc_establecimientos_unificado.csv contiene los datos crudos.

mineduc_establecimientos_limpio.csv contiene los datos limpios finales. El notebook 1.ipynb contiene todo el proceso de obtención, diagnóstico, plan y limpieza.